# Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Автоматизированные системы обработки информации и управления»



### Отчет по лабораторной работе № 5

«Линейные модели, SVM и деревья решений»

по курсу "Методы машинного обучения"

> Выполнил: Али Диб А.Ж. Студент группы ИУ5-22М

## ▼ Цель лабораторной работы:

изучение линейных моделей, SVM и деревьев решений.

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from typing import Dict, Tuple
from sklearn.datasets import *
from sklearn.preprocessing import MinMaxScaler
from sklearn.linear model import LinearRegression, LogisticRegression
from sklearn.model selection import train test split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy score, balanced accuracy score
from sklearn.metrics import precision score, recall score, f1 score, classification
from sklearn.metrics import confusion matrix
from sklearn.metrics import plot confusion matrix
from sklearn.model selection import GridSearchCV
from sklearn.metrics import mean absolute error, mean squared error, mean squared 1
from sklearn.metrics import roc curve, roc auc score
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export grap
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor
from sklearn.ensemble import GradientBoostingClassifier, GradientBoostingRegressor
from sklearn.linear model import RidgeClassifier
%matplotlib inline
sns.set(style="ticks")
import warnings
warnings.filterwarnings("ignore")
   /usr/local/lib/python3.6/dist-packages/statsmodels/tools/ testing.py:19: Future
```

import pandas.util.testing as tm

## Набор данных

В качестве набора данных мы будем использовать набор данных для выявления рака молс https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+(Diagnostic)

```
cancer = load_breast_cancer()
data=pd.DataFrame(data=np.c [cancer['data'],cancer['target']],
                   columns = list(cancer['feature names']) + ['target'])
data.head()
\Box
```

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mea concav point
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.1471
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.0701
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.1279
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.1052
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.1043

data.shape

data.columns

data.dtypes

Гэ

```
mean radius
                             float.64
    mean texture
                            float64
                            float64
    mean perimeter
                             float64
    mean area
                           float64
float64
    mean smoothness
    mean compactness
                            float64
    mean concavity
data.isnull().sum()
                             0
T→ mean radius
    mean texture
    mean perimeter
    mean area
    mean smoothness
    mean compactness
    mean concavity
    mean concave points
    mean symmetry
    mean fractal dimension
    radius error
    texture error
    perimeter error
    area error
    smoothness error
    compactness error
    concavity error
    concave points error
    symmetry error
    fractal dimension error 0
    worst radius
    worst texture
    worst perimeter
    worst area
    worst smoothness
    worst compactness
    worst concavity
    worst concave points
    worst symmetry
    worst fractal dimension 0
    dtype: int64
```

База данных не содержит отсутствующих переменных или переменных категории. Мы мож

```
np.unique(data.target)

C> array([0., 1.])
```

Классы классификации состоят только из двух значений (0 или 1)

## ▶ Разделите выборку на обучающую и тестовую

```
X_train, X_test, y_train, y_test = train_test_split(data[['mean compactness','radiu
```

```
X train.shape, y train.shape
 \Gamma \rightarrow ((113, 9), (113,))
X test.shape, y test.shape
 \Gamma \rightarrow ((456, 9), (456,))
np.unique(y train)
 \Gamma \rightarrow \operatorname{array}([0., 1.])
np.unique(y test)
 \Gamma \rightarrow \operatorname{array}([0., 1.])
```

## Обучиние

Сначала давайте посмотрим, сколько значений в каждом классе.

```
def class proportions(array: np.ndarray) -> Dict[int, Tuple[int, float]]:
    Вычисляет пропорции классов
    array - массив, содержащий метки классов
    # Получение меток классов и количества меток каждого класса
    labels, counts = np.unique(array, return counts=True)
    # Превращаем количество меток в процент их встречаемости
    # делим количество меток каждого класса на общее количество меток
    counts perc = counts/array.size
    # Теперь sum(counts perc)==1.0
    # Создаем результирующий словарь,
    # ключом словаря явлется метка класса,
    # а значением словаря процент встречаемости метки
    res = dict()
    for label, count2 in zip(labels, zip(counts, counts perc)):
        res[label] = count2
    return res
def print_class_proportions(array: np.ndarray):
    Вывод пропорций классов
    proportions = class_proportions(array)
    if len(proportions)>0:
        print('Метка \t Количество \t Процент встречаемости')
    for i in proportions:
```

```
val, val_perc = proportions[i]
val_perc_100 = round(val_perc * 100, 2)
print('{} \t {} \t \t {}\$'.format(i, val, val_perc_100))

print_class_proportions(data.target)

□ Meтка Количество Процент встречаемости
0.0 212 37.26%
1.0 357 62.74%
```

Таким образом, в наборе данных есть небольшой уклон (bias)

#### Оценка качества моделей

для оценки качества каждого классификатора. Мы будем использовать precision, recall, f1 *и* В дополнение к этому мы увидим оценку точности для двух классов отдельно.

```
class MetricLogger:
    def __init__(self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
             'value': pd.Series([], dtype='float')})
    def add(self, metric, alg, value):
        .. .. ..
        Добавление значения
        11 11 11
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].ind
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore index=True)
    def get data for metric(self, metric, ascending=True):
        Формирование данных с фильтром по метрике
        temp data = self.df[self.df['metric']==metric]
        temp data 2 = temp data.sort values(by='value', ascending=ascending)
        return temp data 2['alg'].values, temp data 2['value'].values
    def plot(self, str header, metric, ascending=True, figsize=(5, 5)):
        Вывод графика
        array labels, array metric = self.get data for metric(metric, ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
```


```
rects = axl.barh(pos, array metric,
                          align='center',
                          height=0.5,
                          tick label=array labels)
        ax1.set_title(str header)
        for a,b in zip(pos, array metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        plt.show()
def accuracy score for classes(
    y true: np.ndarray,
    y pred: np.ndarray) -> Dict[int, float]:
    Вычисление метрики ассигасу для каждого класса
    y true - истинные значения классов
    у pred - предсказанные значения классов
    Возвращает словарь: ключ - метка класса,
    значение - Ассигасу для данного класса
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = {'t': y_true, 'p': y_pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp data flt = df[df['t']==c]
        # расчет accuracy для заданной метки класса
        temp acc = accuracy score(
            temp_data_flt['t'].values,
            temp data flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp acc
    return res
def print accuracy score for classes(
    y true: np.ndarray,
    y_pred: np.ndarray):
    Вывод метрики ассигасу для каждого класса
    accs = accuracy_score_for_classes(y_true, y_pred)
    if len(accs)>0:
        print('Merka \t Accuracy')
    for i in accs:
        print('{} \t {}'.format(i, accs[i]))
labels=[1,2]
```

#### модели классификаторов

```
from sklearn import svm
clas_models = { 'LR': LogisticRegression(),
              'SVC':svm.SVC(decision function shape='ovo'),
              'Tree':DecisionTreeClassifier()}
clasMetricLogger = MetricLogger()
def draw roc curve(y true, y score, pos label=1, average='micro'):
   fpr, tpr, thresholds = roc curve(y true, y score,
                                  pos label=pos label)
   roc auc value = roc auc score(y true, y score, average=average)
   plt.figure()
   lw = 2
   plt.plot(fpr, tpr, color='darkorange',
            lw=lw, label='ROC curve (area = %0.2f)' % roc auc value)
   plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
   plt.xlim([0.0, 1.0])
   plt.ylim([0.0, 1.05])
   plt.xlabel('False Positive Rate')
   plt.ylabel('True Positive Rate')
   plt.title('Receiver operating characteristic')
   plt.legend(loc="lower right")
   plt.show()
def clas train model(model name, model, clasMetricLogger):
   model.fit(X train, y train)
   Y pred = model.predict(X test)
   print accuracy score for classes(y test, Y pred)
   precision = precision score(y test.values, Y pred)
   recall = recall score(y test.values, Y pred)
   f1 = f1 score(y test.values, Y pred)
   roc_auc = roc_auc_score(y_test.values, Y_pred)
   clasMetricLogger.add('precision', model name, precision)
   clasMetricLogger.add('recall', model_name, recall)
   clasMetricLogger.add('f1', model name, f1)
   clasMetricLogger.add('roc auc', model name, roc auc)
   print(model)
   draw_roc_curve(y_test.values, Y_pred)
   plot_confusion_matrix(model, X_test, y_test.values,
                    display labels=['0','1'],
                    cmap=plt.cm.Blues, normalize='true')
   plt.show()
```

```
for model_name, model in clas_models.items():
    clas_train_model(model_name, model, clasMetricLogger)
```


С→



Метка Accuracy 0.0 1.0 1.0 1.0


\*\*\*\*\*\*\*\*\*\*\*\*\*

\*\*\*\*\*\*\*\*\*\*\*\*\*\*



```
clas_metrics = clasMetricLogger.df['metric'].unique()

for metric in clas_metrics:
    clasMetricLogger.plot('Meтрика: ' + metric, metric, figsize=(7, 6))
С>
```



## Grid Search для Logistic Regression:


```
I
                                                        clf = LogisticRegression()
grid_values = {'penalty': ['11', '12'], 'C':[0.001,.009,0.01,.09,1,5,10,25]}
grid_clf_acc = GridSearchCV(clf, param_grid = grid_values,scoring = 'recall')
grid_clf_acc.fit(X_train, y_train)
₽
```

```
GridSearchCV(cv=None, error score=nan,
                 estimator=LogisticRegression(C=1.0, class weight=None, dual=False
                                               fit intercept=True,
                                               intercept scaling=1, 11 ratio=None,
                                               max iter=100, multi class='auto',
                                               n jobs=None, penalty='12',
                                               random state=None, solver='lbfgs',
                                               tol=0.0001, verbose=0,
                                               warm start=False),
                 iid='deprecated', n_jobs=None,
                 param grid={'C': [0.001, 0.009, 0.01, 0.09, 1, 5, 10, 25],
grid clf acc.best estimator
□→ LogisticRegression(C=5, class weight=None, dual=False, fit intercept=True,
                       intercept_scaling=1, l1_ratio=None, max_iter=100,
                       multi class='auto', n jobs=None, penalty='12',
                       random state=None, solver='lbfqs', tol=0.0001, verbose=0,
                       warm start=False)
grid_clf_acc.best_params_
□→ {'C': 5, 'penalty': '12'}
clas_models_grid = {'LR_5_12':grid_clf_acc.best_estimator_}
for model name, model in clas models grid.items():
   clas train model(model name, model, clasMetricLogger)
Г⇒
```

## ▼ Grid Search для SVC:

 $\Box$ 

```
Fitting 5 folds for each of 4 candidates, totalling 20 fits
   [CV] gamma=1, kernel=linear .....
   [CV] ..... gamma=1, kernel=linear, total= 0.0s
   [CV] gamma=1, kernel=linear ......
   [CV] ..... gamma=1, kernel=linear, total= 0.0s
   [CV] gamma=1, kernel=linear .....
   [CV] ..... gamma=1, kernel=linear, total= 0.0s
   [CV] gamma=1, kernel=linear .....
   [CV] ..... gamma=1, kernel=linear, total= 0.1s
   [CV] gamma=1, kernel=linear ......
   [Parallel(n jobs=1)]: Using backend SequentialBackend with 1 concurrent workers
   [Parallel(n jobs=1)]: Done 1 out of
                              1 | elapsed: 0.0s remaining:
                                                        0.0:
   [CV] ..... gamma=1, kernel=linear, total=
   [CV] gamma=1, kernel=rbf ......
   [CV] ..... gamma=1, kernel=rbf, total= 0.0s
   [CV] gamma=1, kernel=rbf .....
   [CV] ..... gamma=1, kernel=rbf, total= 0.0s
   [CV] gamma=1, kernel=rbf .....
   [CV] ..... gamma=1, kernel=rbf, total= 0.0s
   [CV] gamma=1, kernel=rbf .....
grid.best estimator
SVC(C=1.0, break ties=False, cache size=200, class weight=None, coef0=0.0,
      decision_function_shape='ovr', degree=3, gamma=1, kernel='linear',
      max iter=-1, probability=False, random state=None, shrinking=True,
      tol=0.001, verbose=False)
                         grid.best params
  {'gamma': 1, 'kernel': 'linear'}
   [CVI] comma=0 1 kornol-rhf
clas models grid = {'SVC 1':grid.best estimator }
   commo-0 1 kornol-rhf total-
for model name, model in clas models grid.items():
  clas train model(model name, model, clasMetricLogger)
Г⇒
```



#### ▼ Grid Search для Decision Tree:

```
params = {'max_leaf_nodes': list(range(2, 100)), 'min_samples_split': [2, 3, 4]}
grid search cv = GridSearchCV(DecisionTreeClassifier(random state=42), params, verb
grid search cv.fit(X train, y train)
    Fitting 3 folds for each of 294 candidates, totalling 882 fits
    [Parallel(n_jobs=1)]: Using backend SequentialBackend with 1 concurrent workers
    [Parallel(n jobs=1)]: Done 882 out of 882 | elapsed:
                                                             2.9s finished
    GridSearchCV(cv=3, error score=nan,
                 estimator=DecisionTreeClassifier(ccp alpha=0.0, class weight=None
                                                   criterion='gini', max depth=None
                                                   max features=None,
                                                   max leaf nodes=None,
                                                   min impurity decrease=0.0,
                                                   min impurity split=None,
                                                   min samples leaf=1,
                                                   min samples split=2,
                                                   min weight fraction leaf=0.0,
                                                   presort='deprecated',
                                                   random state=42,
                                                   splitter='best'),
                 iid='deprecated', n jobs=None,
                 param grid={'max leaf nodes': [2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12
                                                 13, 14, 15, 16, 17, 18, 19, 20, 21
                                                 22, 23, 24, 25, 26, 27, 28, 29, 30
                                                 31, ...],
                              'min_samples_split': [2, 3, 4]},
                 pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
                 scoring='accuracy', verbose=1)
```

grid\_search\_cv.best\_estimator\_

C→

DecisionTreeClassifier(ccp\_alpha=0.0, class\_weight=None, criterion='gini', max\_depth=None, max\_features=None, max\_leaf\_nodes=2, min\_impurity\_decrease=0.0, min\_impurity\_split=None, min\_samples\_leaf=1, min\_samples\_split=2, min\_weight\_fraction\_leaf=0.0, presort='deprecated',

grid search cv.best params

[ \* ('max\_leaf\_nodes': 2, 'min\_samples\_split': 2)


clas models grid = {'Tree':grid search cv.best estimator }

for model\_name, model in clas\_models\_grid.items():
 clas train model(model name, model, clasMetricLogger)

Метка Accuracy 0.0 1.0 1.0 1.0

\*\*\*\*\*\*\*\*\*\*\*\*\*\*

\*\*\*\*\*\*\*\*\*\*\*\*\*\*\*



```
tree cl=grid search cv.best estimator
from sklearn.tree.export import export text
tree rules = export text(tree cl, feature names=list(data[['mean compactness','radi
                                                             'worst smoothness','wors
tree rules
□→ '|--- target <= 0.50\n| |--- class: 0.0\n|--- target > 0.50\n| |--- class
data temp=data[['mean compactness','radius error','concave points error','worst tex
                                                             'worst smoothness','wors
def plot tree classification(title param, ds):
    Построение деревьев и вывод графиков для заданного датасета
    n classes = len(np.unique(ds.target))
   plot colors = "ryb"
   plot step = 0.02
    for pairidx, pair in enumerate([[0, 1], [0, 2], [0, 3], [0,4], [0,5], [0,6], [0,7],
                                     [1,2],[1,3],[1,4],[1,5],[1,6],[1,7],
                                     [2, 3],[2,4],[2,5],[2,6],[2,7],
                                     [3,4],[3,5],[3,6],[3,7],
                                     [4,5],[4,6],[4,7],
                                     [5,6],[5,7],[6,7]]):
        # We only take the two corresponding features
        temp=np.array(ds)
        X = temp[:, pair]
        y = ds.target
        # Train
        clf = DecisionTreeClassifier(random state=1).fit(X, y)
        plt.title(title param)
        x \min_{x \in X} x \max_{x \in X} = X[:, 0].\min() - 1, X[:, 0].\max() + 1
        y_{min}, y_{max} = X[:, 1].min() - 1, X[:, 1].max() + 1
        xx, yy = np.meshgrid(np.arange(x min, x max, plot step),
                              np.arange(y min, y max, plot step))
        plt.tight layout(h pad=0.5, w pad=0.5, pad=2.5)
        Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
        Z = Z.reshape(xx.shape)
        cs = plt.contourf(xx, yy, Z, cmap=plt.cm.RdYlBu)
        plt.xlabel(ds.columns[pair[0]])
        plt.ylabel(ds.columns[pair[1]])
        # Plot the training points
        for i, color in zip(range(n classes), plot colors):
            idx = np.where(y == i)
```