# Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Автоматизированные системы обработки информации и управления»



#### Отчет по лабораторной работе № 6

«Ансамбли моделей машинного обучения»

по курсу "Методы машинного обучения"

> Выполнил: Али Диб А.Ж. Студент группы ИУ5-22М

# Цель лабораторной работы

Изучение ансамблей моделей машинного обучения.

```
from datetime import datetime
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean absolute error
from sklearn.metrics import median absolute error, r2 score
from sklearn.model selection import GridSearchCV
from sklearn.model selection import ShuffleSplit
from sklearn.model selection import train test split
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
# Enable inline plots
%matplotlib inline
# Set plots formats to save high resolution PNG
from IPython.display import set matplotlib formats
set matplotlib formats("retina")
%matplotlib inline
```

### Набор данных

Наш набор данных касается относительных данных о производительности процессора, опи цикла, объема памяти и т. Д.

Информация об атрибутах:

- 1. vendor name
- 2. Model Name: many unique symbols
- 3. MYCT: machine cycle time in nanoseconds (integer)
- 4. MMIN: minimum main memory in kilobytes (integer)
- 5. MMAX: maximum main memory in kilobytes (integer)
- 6. CACH: cache memory in kilobytes (integer)
- 7. CHMIN: minimum channels in units (integer)
- 8. CHMAX: maximum channels in units (integer)
- 9. PRP: published relative performance (integer)
- 10. ERP: estimated relative performance from the original article (integer)

v('https://archive.ics.uci.edu/ml/machine-learning-databases/cpu-performance/machin

Г⇒

	vendor_name	Model_Name	муст	MMIN	MMAX	CACH	CHMIN	СНМАХ	PRP	ERP
0	adviser	32/60	125	256	6000	256	16	128	198	199
1	amdahl	470v/7	29	8000	32000	32	8	32	269	253
2	amdahl	470v/7a	29	8000	32000	32	8	32	220	253
3	amdahl	470v/7b	29	8000	32000	32	8	32	172	253
4	amdahl	470v/7c	29	8000	16000	32	8	16	132	132

data.columns

data.dtypes

₽	vendor_name	object
	Model_Name	object
	MYCT	int64
	MMIN	int64
	MMAX	int64
	CACH	int64
	CHMIN	int64
	CHMAX	int64
	PRP	int64
	ERP	int64
	dtype: object	

data.isnull().sum()

₽	vendor_name	0
_	Model_Name	0
	MYCT	0
	MMIN	0
	MMAX	0
	CACH	0
	CHMIN	0
	CHMAX	0
	PRP	0
	ERP	0
	dtype: int64	

наш набор данных не содержит пропущенных значений. поэтому не надо обрабатывать их. но мы должны иметь дело со столбцами объектов в нашем наборе данных.

# ▼ Кодирование категориальных признаков

```
LE=LabelEncoder()
```

```
data_vendor_name=LE.fit_transform(data['vendor name'])
data['vendor name']=data vendor name
data_Model_Name=LE.fit_transform(data['Model_Name'])
data['Model Name']=data Model Name
data.dtypes

    vendor name

                   int64
    Model Name
                  int64
    MYCT
                   int64
    MMIN
                   int64
    MMAX
                  int64
    CACH
                  int.64
    CHMIN
                   int64
                   int64
    CHMAX
    PRP
                   int64
    ERP
                   int64
    dtype: object
```

разделиние выборку на обучающую и тестовую.

```
X_train, X_test, y_train, y_test = train_test_split(data[['vendor_name','Model_Name
print(X_train.shape)
print(X_test.shape)
print(y_train.shape)
print(y_test.shape)

Drint(y_test.shape)

Drint(y_test.shape)
```

# - Выбор метрик для последующей оценки качества модел

мы будем использовать среднюю абсолютную ошибку и медиану абсолютной ошибки

# Random Forest Regressor

## Gradient Boosting Regressor

## Подбор гиперпараметров для выбранных моделей

```
param_grid = {
    'max_depth' : [1, 2, 3, 4, 5],
    'max_samples' : [0.05, 0.1, 0.2, 0.5],
    'max_leaf_nodes':[10, 15],
    'n_estimators':np.array(range(1,100,10))
}
param_grid
```

```
{'max depth': [1, 2, 3, 4, 5],
     'max leaf nodes': [10, 15],
     'max samples': [0.05, 0.1, 0.2, 0.5],
gs = GridSearchCV(RandomForestRegressor(), param grid,
                 cv=ShuffleSplit(n splits=10), scoring="neg mean squared error",
                   return train score=True, n jobs=-1)
gs.fit(X train, y train)
gs.best estimator
    RandomForestRegressor(bootstrap=True, ccp alpha=0.0, criterion='mse',
                         max depth=4, max features='auto', max leaf nodes=10,
                         max samples=0.5, min impurity decrease=0.0,
                         min_impurity_split=None, min_samples_leaf=1,
                         min samples split=2, min weight fraction leaf=0.0,
                         n estimators=71, n jobs=None, oob score=False,
                         random state=None, verbose=0, warm start=False)
gs.best_params_
reg = gs.best_estimator_
reg.fit(X train, y train)
new metrics RF=test model(reg)
new metrics RF
    {'mean absolute error': 15.760364301003799,
     'median absolute error': 7.665092253800962}
param grid = {
    'max_depth' : [1, 2, 3, 4, 5],
    'max leaf nodes':[10, 15],
    'n_estimators':np.array(range(1,100,10))
}
gbr = GridSearchCV(GradientBoostingRegressor(), param grid,
                           cv=ShuffleSplit(n splits=10), scoring="neg mean squared
                             return train score=True, n jobs=-1)
gbr.fit(X_train, y_train)
gbr.best estimator
GradientBoostingRegressor(alpha=0.9, ccp alpha=0.0, criterion='friedman mse',
                             init=None, learning rate=0.1, loss='ls', max depth=4
                             max_features=None, max_leaf_nodes=10,
                             min impurity decrease=0.0, min impurity split=None,
                             min samples leaf=1, min samples split=2,
                             min weight fraction leaf=0.0, n estimators=61,
                             n_iter_no_change=None, presort='deprecated',
                             random state=None, subsample=1.0, tol=0.0001,
                             validation fraction=0.1, verbose=0, warm start=False
reg = gbr.best estimator
reg.fit(X_train, y_train)
```

### Сравниние качество полученных моделей